PSet #2: Pipeline de Datos End-to-End

Ciencia de Datos

En el PSet #1 definiste un proyecto de ciencia de datos, justificaste su viabilidad y determinaste qué datos necesitas. En este PSet debes construir la infraestructura y la tubería de datos que alimentarán ese proyecto.

El objetivo es implementar un pipeline ELT reproducible desde la fuente hasta Snowflake utilizando Kestra, dbt y Spark.

Al finalizar debes tener:

Fuente → Kestra → Raw → dbt → Bronze → dbt → Silver → dbt → Gold → Spark → OBT

Este PSet termina con datos limpios, modelados y preparados para las siguientes etapas del proyecto.

1. Arquitectura

Diseña e implementa una arquitectura en la que Snowflake sea el destino de los datos.

Kestra debe encargarse de la ingesta y la orquestación. dbt debe realizar las transformaciones y construir las capas Bronze, Silver y Gold. Spark debe utilizarse para construir una One Big Table (OBT) a partir de los datos procesados.

La infraestructura local debe definirse en el archivo `docker-compose.yml` e incluir, como mínimo: Kestra y Spark. Puedes utilizar dbt Core en Docker o en dbt Cloud.

Incluye un diagrama de la arquitectura implementada.

2. Ingesta con Kestra

Construye un flujo en Kestra que extraiga los datos de la fuente de tu proyecto y los cargue en Snowflake.

La ingesta debe poder realizarse sin intervención manual.

Debes implementar y poder explicar:

- Trigger y frecuencia de ejecución
- Manejo de errores y retries

- Backfill de datos históricos.

Los datos originales deben almacenarse en un esquema Raw.

3. Calidad y limpieza de datos

Analiza la calidad de los datos antes de transformarlos.

Como mínimo, debes revisar la completitud, la precisión, la consistencia y la validez.

No basta con limpiar los datos. Debes justificar las decisiones tomadas.

Para los problemas principales, documenta:

Problema	**Evidencia**	**Acción**	**Justificación**
IDs duplicados	120 registros	Conservar registro más reciente	Representa la última actualización

Las transformaciones de limpieza deben realizarse con dbt para generar la capa de Staging.

4. Modelado dimensional con dbt

A partir de Silver construye una capa Gold siguiendo un star schema.

Debes definir claramente el grano de la tabla de hechos y construir las dimensiones necesarias para tu proyecto.

Incluye un diagrama del modelo dimensional.

Tu proyecto de dbt debe utilizar `source()` y `ref()` para gestionar las dependencias entre modelos e incluir pruebas de calidad relevantes, como `not_null`, `unique` y `relationships`.

¡Los tests deben validar las reglas de tus datos y del problema de negocio!

5. OBT con Spark

Utiliza Spark para construir una One Big Table a partir de las tablas Gold.

La OBT debe integrar la información necesaria para alimentar el futuro modelo de ciencia de datos.

Debes definir su grano y validar que los joins no hayan introducido duplicados ni hayan modificado incorrectamente el número de observaciones.

El resultado debe almacenarse nuevamente en Snowflake.

En el documento debes explicar cuándo utilizarías el star schema y cuándo la OBT en tu proyecto.

6. Batch vs. streaming

Tu pipeline se implementará mediante procesamiento por lotes.

Justifica esta decisión considerando la frecuencia con la que se generan los datos y la latencia que realmente requiere el problema de negocio.

Explica también qué tendría que cambiar en el caso de uso para justificar una arquitectura de streaming.

NO debes implementar streaming.

Documento técnico

Entrega un documento técnico de hasta 6 páginas, sin contar los anexos.

El documento debe explicar tu implementación y las decisiones tomadas, NO definir teóricamente qué son Kestra, dbt, Spark o Snowflake.

Debe contener:

1. Arquitectura

Diagrama de la infraestructura y explicación del flujo de datos.

2. Ingesta

Fuente, frecuencia, granularidad, proceso de carga, retries y estrategia de backfill para crear Raw.

3. Data Quality

Problemas encontrados, evidencia y decisiones de limpieza.

Utiliza métricas concretas. Por ejemplo:

> El 4.3% de los registros no tenía `customer_id`.

4. Transformaciones y modelado

Explica la construcción de Bronze, Silver y Gold. Define el grano de la tabla de hechos y presenta el esquema de estrella.

5. Spark y OBT

Explica cómo construiste la OBT, cuál es su grano y cómo validaste los joins.

6. Batch vs. streaming

Justifica por qué el batch es suficiente actualmente y bajo qué condiciones utilizarías streaming.

7. Limitaciones

Documenta problemas de datos o de arquitectura que aún no se hayan resuelto.

Repositorio

El repositorio debe permitir reproducir el pipeline.

La estructura del repo:

```
pset_2/
├── docker-compose.yml
├── .env.example
├── README.md
├── kestra/
├── dbt/
├── spark/
└── docs/
```

El `README.md` debe explicar cómo levantar la infraestructura y ejecutar Kestra, dbt y Spark.

¡No subas contraseñas, tokens ni credenciales al repositorio!

Entregables

Entregable	**Requisito**
Repositorio	Código del pipeline y README
Documento técnico	Máximo 6 páginas
Arquitectura	Diagrama de infraestructura
Snowflake	Raw, Bronze, Silver, Gold y OBT
Kestra	Ingesta, retry y backfill funcionando
dbt	Limpieza, star schema y tests
Spark	Construcción de la OBT

Nombre del documento: `PSet2_memo_<apellido_1>_<apellido_2>.pdf`

Rúbrica

Criterio	**Peso**
Kestra, ingesta y orquestación para Raw	15%
Calidad y limpieza de datos	20%
dbt y arquitectura Bronze/Silver/Gold	15%
Star schema	15%
Spark y OBT	15%
Infraestructura y reproducibilidad	10%
Documento técnico y decisiones de arquitectura	10%
Total	100%